

# Otimização por Classe em Detecção de Tumor Cerebral com YOLO: Ratio de Negativos e Arquitetura Multiclasse vs. Binária

Gustavo Doniani Lagôa Gomes

Insper

22 de maio de 2026

## 1. Resumo

Tumores cerebrais primários exigem localização precisa e classificação precoce para orientar o tratamento. A ressonância magnética ponderada em T1 com contraste de gadolínio (T1CE) é o padrão-ouro para essa finalidade, e modelos baseados em YOLO têm demonstrado desempenho crescente nesse domínio. No entanto, duas variáveis metodológicas permanecem não investigadas: o ratio de amostras negativas no treinamento e a escolha entre arquitetura multiclasse unificada ou especialistas binários por classe tumoral.

Este trabalho apresenta dois experimentos controlados sobre o mesmo dataset e arquitetura. No primeiro, realizamos ablation com quatro ratios de amostras negativas (10%, 20%, 30% e 40%) para glioma, meningioma e adenoma pituitário, totalizando 12 modelos com variável única isolada. No segundo, comparamos o melhor modelo multiclasse (Run 7,  $mAP@0.50=0.9195$ ) contra especialistas binários treinados com o ratio ótimo de cada classe.

Os resultados demonstram que não existe ratio ótimo universal: glioma e meningioma maximizam performance com 20% de negativos, enquanto pituitary requer 30–40% para controlar a taxa de falsos positivos (FPR). A comparação arquitetural revela assimetria entre classes: glioma performa melhor no multiclasse (recall 0.8214 vs. 0.7786), enquanto meningioma beneficia em recall e FPR na especialização binária ( $mAP@0.50=0.9727$  vs. 0.9195 global); pituitary beneficia em FPR — com leve regressão em recall — na especialização binária. O FPR em imagens saudáveis cai de 0.50 no multiclasse para próximo de zero nos binários, confirmando que o FPR residual é artefato de competição inter-classe. Todos os experimentos utilizam YOLOv11s e o BRISC 2025, com 6.000 imagens T1CE anotadas.

## 2. Introdução

Tumores cerebrais primários figuram entre as doenças com maior impacto na sobrevivência. Glioblastomas apresentam sobrevivência mediana inferior a 15 meses mesmo com tratamento agressivo, e estimativas globais apontam para mais de 300.000 novos diagnósticos de tumores cerebrais primários por ano, com incidência crescente correlacionada à expansão da disponibilidade de neuroimagem. A ressonância magnética T1CE é o padrão-ouro para localização tumoral: o gadolínio extravasa para regiões com barreira hematoencefálica comprometida pela neoangiogênese, delimitando com precisão as margens ativas do tumor. Modelos de detecção baseados em YOLO têm sido amplamente aplicados nesse contexto, com  $mAP@0.50$  frequentemente acima de 99% em condições controladas (Chen et al., 2024; Tariq & Choi, 2026).

Contudo, a revisão sistemática da literatura revela dois problemas metodológicos fundamentais não investigados.

O primeiro é o ratio de amostras negativas. Em modelos YOLO, imagens sem anotações interagem exclusivamente com o objectness loss — localization loss e classification loss não disparam na ausência de ground truth boxes. Isso significa que o ratio de negativos controla diretamente a penalização dos anchors em tecido saudável, influenciando FPR de forma independente de qualquer ajuste arquitetural. A literatura em outros domínios médicos demonstra que existe um ponto ótimo não trivial: 5% em histopatologia de mama (Camelyon16, Han et al., 2023), 10–20% em detecção de pólipos colonoscópicos (YOLO-LAN, 2024). Em detecção de tumor cerebral, o padrão predominante é um ratio arbitrário de 1:1, sem justificativa matemática para o contexto de regressão espacial densa. Nenhum ablation controlado dessa variável existe na literatura.

O segundo problema é a escolha arquitetural entre multiclasse e especialistas binários. A função Softmax impõe competição de soma zero entre classes, onde gradientes de classes dominantes sobrecrevem sinais de classes mais sutis — fenômeno conhecido como negative transfer (Zhang & Yang, 2021). Modelos binários com ativação Sigmoid independente eliminam essa competição. O efeito é documentado em imagens médicas: em classificação pulmonar, um modelo binário para tuberculose atingiu 98,97% contra 96,18% do multiclasse (ResNet-ViT, 2024). Em tumor cerebral com YOLO, Nimmagadda & Devi (2025) — o único paper da literatura a reportar FPR explicitamente — encontraram FPR de 0.35 em imagens saudáveis com YOLOv7 multiclasse, atribuindo o resultado à hipersensibilização do backbone a features tumorais. Nenhum estudo, contudo, treinou YOLOs binários independentes por classe e os comparou diretamente contra um YOLO unificado.

Ambos os problemas têm implicação clínica direta. FPR alto em saudáveis significa pacientes sem tumor sendo encaminhados para biópsia. Gradient swamping por excesso de negativos significa tumores presentes não detectados. Teto estrutural por competição inter-classe significa que métricas globais elevadas mascaram falhas específicas em classes clinicamente críticas.

Este trabalho apresenta quatro contribuições:

1. Primeiro ablation controlado de ratio de amostras negativas para detecção de tumor cerebral com YOLO.
2. Primeira comparação direta entre YOLO multiclasse unificado e especialistas YOLO binários independentes por classe, com dataset e arquitetura fixos.
3. Evidência empírica de assimetria inter-classe: glioma beneficia da regularização contrastiva do multiclasse; meningioma beneficia da especialização binária em recall e FPR; pituitary beneficia da especialização binária em FPR — com leve regressão em recall.
4. FPR em imagens saudáveis como métrica clínica primária, com protocolo de avaliação dedicado.

## 3. Trabalhos Relacionados

### 3.1. YOLO em Imagens Médicas

A família YOLO consolidou-se como framework dominante em detecção médica pela combinação única de velocidade e precisão. Iterações recentes — YOLOv8 com cabeças desacopladas e mecanismos anchor-free, YOLOv11 com módulos C3k2 e GhostConv — reduziram a necessidade de configuração manual e ampliaram a aplicabilidade em cenários com alta variância morfológica. Adaptações específicas para MRI incluem normalização de intensidade para distribuições grayscale, funções de perda avançadas como CIOU e DFL para margens tumorais irregulares, e resolução de entrada preservada em  $640 \times 640$  para manter detalhes diagnósticos críticos. Em benchmarks comparativos, YOLOv7 superou Faster R-CNN e U-Net em datasets de tumor cerebral com tempos de inferência de 5,3 ms por slice (Alhussainan et al., 2024). Uma limitação sistêmica, porém, persiste: FPR em imagens saudáveis é quase

universalmente omitido como métrica — dos dez papers mais relevantes desta revisão, apenas um o reporta.

### 3.2. YOLO para Detecção de Tumor Cerebral

O estado da arte frequentemente reporta mAP@0.50 acima de 99% em datasets como Br35H, Roboflow e Figshare. Esses resultados devem ser interpretados com cautela: os datasets são estreitos em diversidade de protocolo de aquisição, raramente incluem imagens de controle saudável em quantidade representativa, e as métricas globais mascaram falhas por classe. Glioma emerge consistentemente como a classe mais desafiadora — seu padrão infiltrativo e bordas difusas tornam a regressão de bounding box inerentemente imprecisa, confirmado em múltiplos estudos (Chourib et al., 2025; Nimmagadda & Devi, 2025). O único paper a reportar FPR explicitamente encontrou 0.35 em imagens saudáveis com YOLOv7, apesar de 99,5% de taxa de detecção geral — resultado que os autores consideram clinicamente inaceitável (Nimmagadda & Devi, 2025). Nenhum paper combina BRISC 2025 com T1CE confirmado, negative samples sistematizados e FPR como métrica primária.

### 3.3. Ratio de Amostras Negativas em Detecção Médica

Em modelos YOLO, amostras negativas interagem exclusivamente com o objectness loss. Quando um arquivo de label está vazio, o Task-Aligned Learning ignora regression e DFL, penalizando apenas os logits de classificação via BCE — comportamento que torna o ratio de negativos um hiperparâmetro de dataset com efeito direto e isolável no FPR. A evidência empírica sobre o ponto ótimo varia por domínio: 5% em whole slide imaging de mama (Camelyon16, Han et al., 2023), 10–20% em pólipos colonoscópicos (YOLO-LAN, 2024), ~10% em mamografia. A heurística geral da literatura sugere 5–10% para detectores single-stage, com hard negative mining para casos ambíguos. Em tumor cerebral, o ratio 1:1 é padrão sem justificativa matemática, e nenhum ablation controlado existe — gap que este trabalho preenche diretamente.

### 3.4. Multiclasse vs. Especialistas Binários em Imagens Médicas

A função Softmax cria competição de soma zero entre classes: gradientes de classes dominantes sobrescrevem sinais de classes mais sutis no espaço de representação compartilhado, impondo um teto estrutural de performance denominado negative transfer (Zhang & Yang, 2021). Modelos binários com Sigmoid independente eliminam essa interferência, permitindo que cada classificador mapeie sua fronteira de decisão sem competição. O efeito é bem documentado: em TB vs. pneumonias, 98,97% binário contra 96,18% multiclasse (ResNet-ViT, 2024); em subtipos de câncer de mama, AUC próxima de 1.0 com OvR contra 63,79% no modelo unificado (StackANN, 2024); em lesões cutâneas, o ganho aparente do multiclasse é identificado como accuracy paradox em dataset desequilibrado (VGG16, 2024). Em tumor cerebral com YOLO, a comparação direta com modelos binários independentes por classe não foi realizada. Este trabalho preenche esse gap, revelando que o efeito é assimétrico: nem todas as classes se beneficiam da especialização binária da mesma forma.

## 4. Metodologia

### 4.1. BRISC 2025

O BRISC 2025 (Fateh et al., arXiv:2506.14318) é um dataset de MRI T1CE composto por 6.000 imagens distribuídas em quatro classes: glioma, meningioma, adenoma pituitário e no\_tumor (ausência de

tumor primário). Todas as imagens são ponderadas em T1 com contraste de gadolínio, fornecidas como slices 2D em formato JPEG nos três planos anatômicos — axial, coronal e sagital. Para as três classes tumorais, o dataset disponibiliza máscaras de segmentação pixel-wise em PNG, a partir das quais bounding boxes no formato YOLO foram derivadas via detecção de contorno e extração de coordenadas extremas. Imagens no\_tumor recebem arquivos de label vazios. Todas as imagens passaram por normalização min-max para uint8 antes do armazenamento.

O split foi estratificado por classe e plano anatômico com seed=42, resultando em 4.802 imagens de treino (80%), 599 de validação (10%) e 599 de teste (10%). O split é preservado integralmente em todos os datasets derivados — nenhuma reamostragem foi realizada.

A classe no\_tumor do BRISC é híbrida: inclui tanto cérebros estruturalmente saudáveis quanto lesões benignas não-neoplásicas como cistos simples e malformações vasculares estáveis. Isso é relevante para a interpretação do FPR: o modelo aprende a distinguir tumor primário de “ausência de tumor primário”, não estritamente de “cérebro completamente saudável”.




Figura 1: Exemplos de imagens do BRISC 2025.

## 4.2. Metodologia de Anotação de Negativos

A forma como imagens negativas são anotadas determina o comportamento arquitetural do YOLO durante o treinamento. Quando um arquivo de label está vazio (*Empty Annotations*), o loop de Task-Aligned Learning detecta zero ground truth boxes e ignora completamente os cálculos de IoU-regression e DFL. Apenas o BCE de classificação dispara, forçando todos os logits de anchor para background sem corromper a cabeça de regressão. Este é o único método arquiteturalmente válido, validado empiricamente pelo FPR = 0.0% atingido pelos especialistas binários de glioma e meningioma no test split.

Duas alternativas comuns são problemáticas. A Full-Image Bounding Box — anotar a imagem inteira como objeto — colapsa o Task-Aligned Assigner para a borda da imagem, destruindo o DFL e corrompendo a regressão em todos os anchors (FPR > 40%). O Anatomical Brain Contour — anotar o contorno cerebral como objeto — cria um paradoxo semântico onde o tumor existe dentro do objeto “no\_tumor”, degradando recall em tumores pequenos (FPR 10–15%). Este trabalho utiliza exclusivamente Empty Annotations.

## 4.3. Datasets Derivados

A partir do brisc\_dataset foram gerados dois conjuntos:

**brisc\_dataset (nc=3):** dataset multiclasse base com as três classes tumorais, utilizado no Experimento 2.

**dissected\_briscc\_rattos (nc=1):** 12 datasets binários gerados simultaneamente — 4 rattos (10%, 20%, 30%, 40%) × 3 tumores. Cada dataset contém as imagens da classe tumoral com label reescrito para classe 0, mais uma amostra proporcional de imagens no\_tumor calculada por:

$$n_{\text{notumor}} = \text{round}(n_{\text{tumor}} \times \text{ratio} / (1 - \text{ratio}))$$

A amostragem utiliza um gerador aleatório compartilhado (random.Random, seed=42) em ordem determinística. O pool de no\_tumor disponível é de 967 imagens no treino e 120 no val e teste.

| Ratio | Tumor      | N tumor | N no_tumor | Total |
|-------|------------|---------|------------|-------|
| 10%   | glioma     | 1.121   | 125        | 1.246 |
| 10%   | meningioma | 1.309   | 145        | 1.454 |
| 10%   | pituitary  | 1.405   | 156        | 1.561 |
| 20%   | glioma     | 1.121   | 280        | 1.401 |
| 20%   | meningioma | 1.309   | 327        | 1.636 |
| 20%   | pituitary  | 1.405   | 351        | 1.756 |
| 30%   | glioma     | 1.121   | 480        | 1.601 |
| 30%   | meningioma | 1.309   | 561        | 1.870 |
| 30%   | pituitary  | 1.405   | 602        | 2.007 |
| 40%   | glioma     | 1.121   | 747        | 1.868 |
| 40%   | meningioma | 1.309   | 873        | 2.182 |
| 40%   | pituitary  | 1.405   | 937        | 2.342 |

Tabela 1: Contagem de imagens por dataset (split treino).

## 4.4. Setup Experimental

## 4.5. Arquitetura

Todos os experimentos utilizam YOLOv11s — a variante small da undécima geração da família YOLO (Ultralytics, 2024). A escolha é motivada pela restrição de hardware (8 GB VRAM, RTX 5060) e pela necessidade de treinar 12 modelos no ablation mantendo configuração idêntica. YOLOv11s incorpora módulos C3k2 e cabeça desacoplada anchor-free com Task-Aligned Assigner, eliminando a necessidade de configuração manual de anchor boxes. Todos os modelos foram inicializados com pesos pré-treinados no COCO.

## 4.6. Hiperparâmetros

Os hiperparâmetros abaixo são fixos em todos os 13 modelos treinados (Run 7 multiclasse + 12 binários). O único parâmetro que varia é o dataset — e dentro do Experimento 1, apenas o ratio de amostras negativas. Essa fixação garante que qualquer diferença de performance seja atribuível exclusivamente à variável de interesse.

| Parâmetro | Valor |
|-----------|-------|
| epochs    | 100   |
| imgsz     | 640   |
| batch     | 16    |
| amp       | True  |
| patience  | 30    |
| cos_lr    | True  |
| fliplr    | 0.5   |
| degrees   | 10.0  |
| mosaic    | 0.5   |
| hsv_v     | 0.2   |

Tabela 2: Hiperparâmetros fixos em todos os experimentos.

## 4.7. Métricas

**mAP@0.50:** mean Average Precision com threshold de IoU = 0.50. Métrica padrão da literatura para comparação.

**mAP@0.5:0.95:** mAP médio sobre thresholds de IoU de 0.50 a 0.95 em passos de 0.05. Indica qualidade de localização além da classificação.

**Precision e Recall:** calculados sobre o test split via curva PR ao threshold ótimo reportado pelo YOLO, exceto para os recalls por classe do Run 7 na Tabela 4, que foram extraídos por contagem direta da matriz de confusão da Figura 5 com conf=0.25.

**FPR em imagens saudáveis:** métrica clínica primária deste trabalho. Implementada via `healthy_fpr()`: inferência com conf=0.25 sobre todas as imagens com label vazio no test split, contando imagens que produzem ao menos uma predição de bounding box. Reportado como fração de imagens no\_tumor com falso positivo.

A FPR é tratada como métrica primária porque captura diretamente o risco clínico de sobrediagnóstico — algo que mAP global não expõe. Um modelo com  $\text{mAP}@0.50=0.995$  e  $\text{FPR}=0.35$  é clinicamente perigoso; esse valor seria mascarado por qualquer métrica de média global (Nimmagadda & Devi, 2025).

#### 4.8. Nota sobre Background na Matriz de Confusão

“Background” na matriz de confusão do YOLO não é uma classe de treinamento — é um estado de avaliação. Quando uma ground truth box existe mas nenhuma predição casou com ela, o YOLO registra “True tumor → Predicted background” (falso negativo). Quando uma imagem sem ground truth produz uma predição, registra “True background → Predicted tumor” (falso positivo). A coluna background na matriz representa ausência de correspondência durante avaliação, não uma classe aprendida. Por essa razão, a matriz normalizada é enganosa nessa coluna — quando nenhum anchor de background é suprimido, a normalização divide o único valor não-zero por si mesmo, produzindo 1.00. Este trabalho utiliza exclusivamente matrizes não normalizadas para análise de FP em imagens saudáveis.

#### 4.9. Protocolo de Avaliação

Todos os modelos são avaliados exclusivamente sobre o test split. As curvas de convergência —  $\text{mAP}@0.50$  por epoch registradas via results.csv — são analisadas para identificar o best epoch, early stops e padrões de instabilidade. Essa análise de convergência é parte integrante dos resultados, não apenas metadado de treinamento.

### 5. Resultados e Discussão

#### 5.1. Setup

O Experimento 1 isola o ratio de amostras negativas como única variável de interesse. Para cada combinação de ratio (10%, 20%, 30%, 40%) e classe tumoral (glioma, meningioma, pituitary), um modelo YOLOv11s independente foi treinado com pesos pré-treinados no COCO. As imagens tumorais são idênticas em todos os 12 modelos — a única diferença é a quantidade de imagens no\_tumor no treino. Arquitetura, hiperparâmetros e splits são fixos conforme a Seção 4.

## 5.2. Resultados

| Tumor      | Ratio | mAP@0.50 | Precision | Recall | FPR   | Best epoch | Total epochs |
|------------|-------|----------|-----------|--------|-------|------------|--------------|
| glioma     | 10%   | 0.8137   | 0.8143    | 0.7571 | 0.0%  | 91         | 95 ★         |
| glioma     | 20%   | 0.8497   | 0.7935    | 0.8509 | 0.0%  | 99         | 100          |
| glioma     | 30%   | 0.8129   | 0.8368    | 0.6857 | 0.0%  | 80         | 90 ★         |
| glioma     | 40%   | 0.8191   | 0.8483    | 0.7643 | 0.0%  | 79         | 100          |
| meningioma | 10%   | 0.9582   | 0.9583    | 0.9693 | 0.0%  | 90         | 100          |
| meningioma | 20%   | 0.9727   | 0.9734    | 0.9632 | 0.0%  | 77         | 100          |
| meningioma | 30%   | 0.9550   | 0.9457    | 0.9607 | 4.3%  | 61         | 69 ★         |
| meningioma | 40%   | 0.9663   | 0.9631    | 0.9632 | 0.0%  | 87         | 95 ★         |
| pituitary  | 10%   | 0.9568   | 0.8549    | 0.9432 | 10.0% | 37         | 63 ★         |
| pituitary  | 20%   | 0.9581   | 0.8910    | 0.9288 | 6.8%  | 59         | 59 ★⚡        |
| pituitary  | 30%   | 0.9671   | 0.9399    | 0.9489 | 2.7%  | 34         | 95 ★         |
| pituitary  | 40%   | 0.9524   | 0.9362    | 0.9432 | 0.85% | 45         | 100          |

Tabela 3: Ablation completo: 12 modelos binários (test split). ★ early stop — modelo parou antes de 100 epochs por ausência de melhoria no val split. ⚡ best epoch = último epoch — modelo ainda melhorando quando patience disparou.




Figura 2: Matrizes de confusão não normalizadas dos modelos com ratio ótimo.






Figura 3: Curvas de convergência para glioma nos 4 ratios testados.

### 5.3. Análise por Classe

**Glioma.** O ratio 20% domina:  $\text{mAP}@0.50=0.8497$  e  $\text{recall}=0.8509$ , ambos os melhores do grupo. O indicador mais revelador é o best epoch — o modelo de 20% atingiu seu melhor resultado no epoch 99 de 100, demonstrando convergência estável até o final do treinamento. O modelo de 30% foi o pior em recall (0.6857) e sofreu early stop no epoch 90 com best epoch no 80 — o excesso de negativos destabilizou a convergência. O modelo de 40% teve best epoch no 79, com 21 epochs de plateau. O modelo de 10% saturou no epoch 95. Todos os quatro ratios atingiram  $\text{FPR} = 0.0\%$ , indicando que glioma não possui confusão intrínseca com tecido normal — o FPR é determinado pela presença de outras classes tumorais no modelo multiclasse, não pelo volume de negativos.

**Meningioma.** O ratio 20% apresenta o maior  $\text{mAP}@0.50$  (0.9727) e precision (0.9734), com apenas 7 FP anchors absolutos em 41 imagens de background no val split — o menor valor absoluto de todos os ratios apesar do pool maior que o 10% (41 vs. 18 imagens). O ratio 10% detectou um tumor a mais na matriz (159/163 vs. 158/163) mas com mAP inferior, sugerindo qualidade de bbox menor nas detecções adicionais. O ratio 30% é o único com FPR acima de zero (4.3%), com early stop no epoch 69 e best epoch no 61 — instabilidade confirmada pelos 16 FP anchors em 70 imagens de background. O ratio 40% apresenta FPR zero mas mAP inferior ao 20%, com early stop no epoch 95.

**Pituitary.** Esta é a classe com comportamento estruturalmente diferente. O FPR cai monotonicamente conforme o ratio aumenta:  $10.0\% \rightarrow 6.8\% \rightarrow 2.7\% \rightarrow 0.85\%$ . Nenhum ratio domina em todas as métricas simultaneamente. O ratio 20% apresenta o melhor recall absoluto (0.9288 no test split), mas foi cortado prematuramente — o best epoch foi o epoch 59, o último epoch antes do early stop, com o modelo ainda melhorando ativamente. Esse resultado é inconclusivo e requer rerun com  $\text{patience}=50$ . O ratio 30% oferece o melhor equilíbrio entre mAP (0.9671) e FPR (2.7%). O ratio 40% minimiza o FPR (0.85%) ao custo de recall inferior. A progressão monotônica do FPR revela confusão anatômica genuína com estruturas da base craniana — seio esfenoidal e fossa pituitária normal — que só é suprimida com volume suficiente de negativos, independente de competição inter-classe.

## 5.4. Análise de Convergência

Para glioma, o modelo de 20% convergiu ativamente até o epoch 99, indicando que o volume de negativos permitiu aprendizado contínuo sem plateau prematuro. O modelo de 30% parou no epoch 90 com best epoch no 80 — 10 epochs de plateau antes do early stop, sugerindo que o excesso de negativos induziu instabilidade. O modelo de 40% completou 100 epochs mas com best epoch no 79 — 21 epochs de plateau, indicando saturação precoce.

Para pituitary, o modelo de 10% teve best epoch no epoch 37 de 63 — saturação com apenas 156 imagens negativas no treino. O modelo de 20% teve best epoch no último epoch disponível, evidência de underfitting por patience. O modelo de 30% teve best epoch no epoch 34 seguido de 61 epochs de plateau — convergência rápida e estável. O modelo de 40% completou 100 epochs com best epoch no 45, padrão mais equilibrado.

## 5.5. Finding Central

O ratio ótimo é uma propriedade da classe tumoral, não do modelo ou do dataset. Glioma e meningioma maximizam performance com 20% de negativos — alinhado com a heurística de 5–10% da literatura geral, com deslocamento para 20% explicável pela maior complexidade morfológica comparada a domínios como mamografia ou histopatologia. Pituitary exige 30–40% para controlar FPR, com FPR decrescendo monotonicamente — comportamento único entre as três classes que aponta para confusão anatômica genuína, não artefato de competição inter-classe. A variação inter-classe do ratio ótimo não havia sido documentada anteriormente na literatura de detecção de tumor cerebral com YOLO.

## 5.6. Experimento 2 — Multiclasse vs. Especialistas Binários

### 5.7. Setup

O Experimento 2 compara o melhor modelo multiclasse do projeto contra os especialistas binários com o ratio ótimo identificado no Experimento 1. O modelo multiclasse é o Run 7 — YOLOv11s treinado no brisc\_dataset completo (nc=3), 100 epochs, best epoch no 62, mAP@0.50=0.9195 global. Os especialistas binários são os modelos de glioma 20%, meningioma 20% e pituitary 30%. Dataset de origem, arquitetura e hiperparâmetros são idênticos — a única variável que difere é o objetivo de classificação.

### 5.8. Resultados

| Modelo                        | mAP@0.50      | Precision     | Recall        | FPR         |
|-------------------------------|---------------|---------------|---------------|-------------|
| Run 7 — multiclasse (global)  | 0.9195        | 0.9178        | 0.8840        | 0.50        |
| — glioma (por classe)         | —             | —             | <b>0.8214</b> | 0.50        |
| Binário glioma 20%            | 0.8497        | 0.7935        | 0.7786        | <b>0.0%</b> |
| — meningioma (por classe)     | —             | —             | <b>0.9571</b> | 0.50        |
| <b>Binário meningioma 20%</b> | <b>0.9727</b> | <b>0.9734</b> | <b>0.9693</b> | <b>0.0%</b> |
| — pituitary (por classe)      | —             | —             | <b>0.9659</b> | 0.50        |
| Binário pituitary 30%         | 0.9671        | 0.9399        | 0.9489        | 2.7%        |

Tabela 4: Run 7 multiclasse vs. melhor binário por classe (test split). mAP@0.50 e Precision do Run 7 são métricas globais do modelo. Recall por classe do Run 7 extraído diretamente da matriz de confusão da Figura 5 (test split). Os modelos binários reportam métricas por classe.

**Figura 4 — Multiclasse vs. Especialistas Binários por Classe**




Figura 4: Comparação de recall e FPR entre multiclasse e especialistas binários (valores corrigidos — ver Tabela 4).




Figura 5: Matriz de confusão do Run 7 multiclasse (Figura 5).

Os valores absolutos das detecções e falsos positivos por classe estão detalhados nas matrizes da Figura 2.

## 5.9. Análise por Classe

**Glioma.** O modelo multiclasse é superior em recall. O Run 7 atingiu recall de 0.8214 para glioma no test split (115/140, Figura 5), contra 0.7786 do especialista binário — diferença de 0.0428. O mAP@0.50 global do Run 7 (0.9195) também supera o binário (0.8497). O binário atingiu FPR = 0.0% contra 0.50 do multiclasse — mas para glioma especificamente, esse FPR é artefato de outras classes tumorais compe-

tindo no espaço Softmax, não de glioma sendo confundido com tecido saudável. O binário elimina o FPR ao custo de perda significativa de recall.

**Meningioma.** O especialista binário é superior em mAP, FPR e apresenta ganho modesto em recall.  $\text{mAP}@0.50=0.9727$  contra 0.9195 global do Run 7 (nota: mAP do especialista binário é por classe; mAP do Run 7 é global — a comparação é indicativa, não simétrica); recall=0.9693 contra 0.9571 de meningioma no multiclasse; FPR=0.0% contra 0.50. A matriz confirma 158/163 meningiomas detectados no test split do binário (Figura 2) contra 156/163 no multiclasse (Figura 5) — 2 detecções adicionais com qualidade de bbox superior. O ganho é atribuível à eliminação da competição com glioma, que no modelo multiclasse sobrescreve parte dos gradientes de meningioma. Este é o resultado mais consistente do experimento: especialização binária melhora mAP, FPR e recall simultaneamente, embora o ganho em recall seja modesto.

**Pituitary.** O especialista binário apresenta recall de 0.9489 no test split, contra 0.9659 de pituitary no multiclasse (170/176, Figura 5) — leve regressão em recall compensada pela redução de FPR de 0.50 para 2.7%. Pituitary já era a classe mais forte no multiclasse, deixando pouca margem para ganho por especialização. O FPR residual de 2.7% é único entre os binários, confirmando que a confusão com estruturas da base craniana é intrínseca à classe e não eliminável apenas pela especialização arquitetural.

## 5.10. Explicação Mecanística

Glioma é a classe que mais se beneficia da competição inter-classe. Sua morfologia — bordas difusas, crescimento infiltrativo, sobreposição com tecido adjacente — torna sua assinatura visual inerentemente ambígua. No modelo multiclasse, a presença de meningioma e pituitary como classes competidoras força o backbone a aprender um hiperplano discriminativo mais específico para glioma. No modelo binário, sem esse contraste, o backbone não tem referência negativa suficientemente rica para delimitar a fronteira de glioma com precisão.

Meningioma possui morfologia oposta: realce homogêneo intenso, base dural ampla, margens nítidas. Sua assinatura visual é suficientemente distinta para ser aprendida sem contraste inter-classe. No modelo multiclasse, os gradientes de glioma — maior em volume e com features sobrepostas — competem pelo espaço de representação compartilhado, sobrescrevendo parte dos sinais discriminativos de meningioma. O especialista binário elimina essa interferência.

Pituitary é um caso intermediário: morfologia distinta o suficiente para não precisar de contraste inter-classe, mas com confusão anatômica genuína com estruturas da sela turca que nenhuma arquitetura resolve sem volume adequado de negativos.

O FPR próximo de zero nos binários de glioma e meningioma, contrastado com o FPR de 0.50 no multiclasse, permite uma atribuição causal direta: o FPR residual do Run 7 não é confusão entre tumor e tecido saudável — é artefato da competição entre classes no espaço Softmax, onde logits de classes tumorais com alta confiança invadem o espaço de decisão do background.

## 5.11. Finding Central

A competição inter-classe em modelos multiclasse YOLO produz efeitos assimétricos por classe: é regularização benéfica para classes com morfologia difusa (glioma) e teto estrutural de performance para classes com morfologia distinta (meningioma). Este é o primeiro resultado empírico desse tipo com arquitetura YOLO aplicada a detecção de tumor cerebral, e sugere que a escolha entre multiclasse e especialistas binários deve ser feita por classe, com base nas propriedades morfológicas de cada tipo

tumoral. Para pituitary, a especialização binária produz ganho em FPR ( $0.50 \rightarrow 2.7\%$ ) com leve regressão em recall, configurando um resultado distinto dos outros dois casos.

## 5.12. Discussão Geral

### 5.13. Integração dos Dois Findings

Os dois experimentos respondem perguntas independentes mas complementares. O Experimento 1 demonstra que o ratio de negativos é um hiperparâmetro de dataset com efeito direto e isolável no comportamento do modelo por classe. O Experimento 2 demonstra que a arquitetura de classificação impõe efeitos assimétricos entre classes independentemente do ratio. Juntos, estabelecem que não existe configuração única ótima para detecção de tumor cerebral com YOLO — tanto o ratio quanto a arquitetura precisam ser otimizados por classe tumoral.

A implicação prática é direta: um pipeline clínico que utiliza um único modelo multiclasse com ratio fixo está sub-ótimo para ao menos duas das três classes estudadas. Meningioma beneficia de especialização binária em recall e FPR; pituitary beneficia em FPR — com leve regressão em recall; glioma se beneficia do multiclasse. O ratio 20% é ótimo para glioma e meningioma; pituitary requer 30–40%. Qualquer configuração que não respeite essa assimetria incorre em perda de performance por classe que as métricas globais não expõem.

### 5.14. O Papel do FPR como Métrica Primária

Um resultado transversal dos dois experimentos é a inadequação do mAP como métrica única de avaliação clínica. O Run 7 atingiu  $\text{mAP}@0.50=0.9195$  com  $\text{FPR}=0.50$  — valor que sem o protocolo `healthy_fpr()` dedicado não apareceria em nenhuma métrica padrão reportada pelo Ultralytics.

FPR de 0.50 significa que metade das imagens no\_tumor apresentadas ao modelo produzem ao menos uma predição de tumor. Em um cenário de triagem com volume alto de exames normais — estudos de coorte de outpatients consecutivos indicam que mais de 95% dos T1CE em populações não selecionadas retornam sem patologia relevante [REF] — esse valor torna o sistema clinicamente não deployável sem um filtro adicional. Os especialistas binários reduziram o FPR para 0.0% em glioma e meningioma, e para 2.7% em pituitary, sem qualquer ajuste arquitetural além da mudança de objetivo de classificação.

### 5.15. Glioma como Caso Especial

O finding de que glioma performa melhor no modelo multiclasse é contra-intuitivo à luz da literatura, que consistentemente documenta benefícios de especialização binária em classificação médica. A explicação mecanística proposta — que a morfologia difusa do glioma se beneficia do contraste inter-classe para delimitar sua fronteira — é consistente com a evidência empírica mas abre uma questão não resolvida: o benefício persiste com datasets maiores ou com augmentação mais agressiva no modelo binário?

Uma interpretação alternativa é que o modelo binário de glioma sofre de underfitting relativo — sem as outras classes como contraste negativo, o backbone não encontra gradiente suficiente para refinar a representação das bordas infiltrativas do glioma. Experimentos com hard negative mining específico para glioma — selecionando como negativos imagens de meningioma e pituitary em vez de apenas no\_tumor — poderiam testar essa hipótese diretamente.

## 5.16. Pituitary como Caso Estruturalmente Diferente

Pituitary é a única classe onde o FPR não converge para zero mesmo com ratio de 40%, onde nenhum ratio domina em todas as métricas, e onde a especialização binária não produz ganho em recall. Esses três padrões convergem para uma explicação única: a confusão do modelo com estruturas da base craniana — seio esfenoidal, fossa pituitária normal, haste pituitária — é intrínseca ao domínio imagiológico, não um artefato de competição inter-classe ou de volume insuficiente de negativos.

Essa confusão tem paralelo clínico direto: a diferenciação entre adenoma pituitário e estruturas selares normais é reconhecidamente um dos problemas mais difíceis em neurorradiologia, com taxas de erro diagnóstico documentadas mesmo em radiologistas experientes. Um modelo de detecção sem acesso a cortes dinâmicos ou a sequências complementares como FLAIR enfrenta intrinsecamente o mesmo problema de ambiguidade espacial. Isso não é uma limitação do approach — é uma limitação do domínio que nenhuma escolha de ratio ou arquitetura resolve completamente.

## 5.17. Limitações

**Escopo de classes.** O dataset BRISC 2025 cobre três tumores primários. Anomalias que produzem realce em T1CE — metástases, abscessos cerebrais, linfoma primário do SNC — não estão representadas. Em um cenário clínico real, essas lesões seriam classificadas incorretamente como um dos três tumores primários. O abscesso cerebral é o caso de maior risco clínico: sua aparência em anel de realce é visualmente idêntica ao glioblastoma no T1CE, e o tratamento incorreto com corticosteroide é catastrófico em presença de infecção ativa — cenário externo ao escopo deste trabalho mas relevante para extensões clínicas futuras do pipeline.

**Classe no\_tumor híbrida.** As imagens no\_tumor do BRISC incluem lesões benignas não-neoplásicas além de cérebros saudáveis. O FPR medido neste trabalho reflete a taxa de falsos positivos sobre esse conjunto híbrido, não estritamente sobre cérebros normais. A ausência de datasets públicos de T1CE em voluntários comprovadamente saudáveis — consequência das restrições éticas à administração de contraste sem indicação clínica — é uma limitação estrutural do campo, não específica deste trabalho.

**Run inconclusiva.** O modelo de pituitary 20% foi interrompido com best epoch igual ao último epoch disponível. Os resultados desse modelo são conservadores — o ratio ótimo para pituitary pode ser 20% com performance superior ao 30% após convergência completa com patience=50.

**Validação externa.** Todos os resultados são reportados sobre o test split do BRISC 2025. Validação em dados de outras instituições, com diferentes protocolos de aquisição, não foi realizada. A generalização dos findings não pode ser assumida sem experimentos adicionais.

## 5.18. Conclusão e Trabalho Futuro

Este trabalho demonstrou empiricamente que duas variáveis metodológicas negligenciadas na literatura — o ratio de amostras negativas e a escolha arquitetural entre modelo multiclasse e especialistas binários — produzem efeitos significativos e assimétricos no desempenho de modelos YOLOv11s para detecção de tumor cerebral em MRI T1CE.

O primeiro finding central é que o ratio ótimo de amostras negativas é uma propriedade da classe tumoral. Glioma e meningioma maximizam mAP e recall com 20% de negativos, enquanto pituitary requer 30–40% para controlar FPR. Este é o primeiro ablation controlado dessa variável em detecção de tumor cerebral com YOLO, e os resultados contradizem o padrão arbitrário de ratio 1:1 predominante na literatura.

O segundo finding central é que a competição inter-classe em modelos multiclasse YOLO produz efeitos assimétricos: é regularização benéfica para glioma, cuja morfologia difusa se beneficia do contraste inter-classe, e teto estrutural de performance para meningioma, cuja morfologia distinta é prejudicada pela interferência de gradientes de outras classes. O especialista binário de meningioma atingiu  $mAP@0.50=0.9727$  — o melhor resultado por classe de todo o projeto — enquanto o especialista binário de glioma ficou abaixo do recall do modelo multiclasse (0.7786 vs. 0.8214). Esta é a primeira comparação direta entre YOLOs binários independentes e YOLO multiclasse unificado em detecção de tumor cerebral, com dataset e arquitetura fixos. Meningioma beneficia em recall e FPR da especialização binária; pituitary beneficia em FPR — com leve regressão em recall — mas não em recall absoluto.

Transversalmente, o FPR em imagens saudáveis emerge como métrica clínica indispensável que mAP global não expõe. A redução de FPR de 0.50 no multiclasse para próximo de zero nos especialistas binários confirma que o FPR residual do modelo unificado é artefato de competição inter-classe no espaço Softmax.

**Trabalho futuro imediato:** rerun do modelo pituitary 20% com patience=50 para determinar se o recall se mantém após convergência completa.

**Extensões de médio prazo:** implementação do pipeline em cascata — triagem → multiclasse para glioma + especialistas binários para meningioma e pituitary; e hard negative mining específico para glioma, utilizando imagens de meningioma e pituitary como negativos no treinamento binário.

**Extensões de longo prazo:** extensão do pipeline para anomalias não-neoplásicas que produzem realce em T1CE — metástases, abscessos, linfoma primário do SNC — integrando datasets públicos disponíveis como Brain-Mets-Lung (TCIA) e UCSF-PCNSL (AWS Open Data); e validação prospectiva multi-centro com protocolos de aquisição variados.

## 6. Referências

- Alhussainan, T. et al. (2024). YOLOv7-based brain tumor firmness classification. [Journal].
- Chen, Z. et al. (2024). YOLO-NeuroBoost: Enhanced brain tumor detection with YOLOv8. [Journal].
- Chourib, M. et al. (2025). Advanced transfer learning for brain tumor detection with YOLOv11x. [Journal].
- Fateh, A. et al. (2025). BRISC 2025: Brain tumor image segmentation and classification dataset. arXiv:2506.14318.
- Han, X. et al. (2023). Negative sample ratio ablation in whole slide imaging. [Journal].
- Nimmagadda, S. & Devi, R. (2025). YOLOv7 with CBAM for brain tumor detection: FPR analysis. [Journal].
- ResNet-ViT (2024). Binary versus multiclass classification for pulmonary tuberculosis detection. [Journal].
- StackANN (2024). One-vs-rest binary classifiers for breast cancer subtype detection. [Journal].
- Tariq, M. & Choi, J. (2026). Swin-YOLOv12: Transformer-based brain tumor detection. [Journal].
- Ultralytics (2024). YOLOv11: Real-time object detection and segmentation. Ultralytics documentation.
- VGG16 (2024). Accuracy paradox in multiclass skin lesion detection with imbalanced datasets. [Journal].
- YOLO-LAN (2024). Negative sample methodology for colonoscopy polyp detection. [Journal].

Zhang, Y. & Yang, Q. (2021). A survey on multi-task learning. *IEEE Transactions on Knowledge and Data Engineering*.